四组对照评估：当前可交付成果

负责人 D：LIANG SHUANG

更新：C 正式管线已接入，四组验证已重跑。 当前使用 A 的固定划分、C 的原始正式实现和 D 的统一评估。C 的14项测试、D的12项检查均通过。B 的发现尚未收到，成员人工复核待完成，测试集尚未进行预测评价。

研究问题：特殊值语义与未知信息处理如何影响同一逻辑回归的可靠性？不调参，不改变阈值，不增加复杂模型。

实验	S：联系历史表示	U：job/education unknown
E0	原始 pdays，保留 -1	训练集众数填补
ES	状态标记 + 条件间隔	训练集众数填补
EU	原始 pdays，保留 -1	独立类别
ESU	状态标记 + 条件间隔	独立类别

实际验证结果

实验	AP ↑	Recall ↑	F1 ↑	Brier ↓	Accuracy
E0	0.358497	0.172968	0.277273	0.089328	0.894492
ES	0.359485	0.172968	0.277273	0.089325	0.894492
EU	0.358526	0.171078	0.274659	0.089337	0.894271
ESU	0.359403	0.172023	0.275967	0.089333	0.894382

train：27,126 行、3,173 正例；validation：9,042 行、1,058 正例、7,984 负例。阈值 p≥0.5。四组输入样本完全相同，编码后维数依次为 31 / 32 / 33 / 34；全部收敛，无收敛警告。

核心结论：语义更清楚，不等于所有指标都更好。

S 的 AP 改善很小；U 的方向不稳定。ESU 相对 E0 的 AP 增加 0.000905，但 Recall 减少 0.0945 个百分点、Brier 增加约 0.00000465。没有不确定性区间，不能称为显著改善。

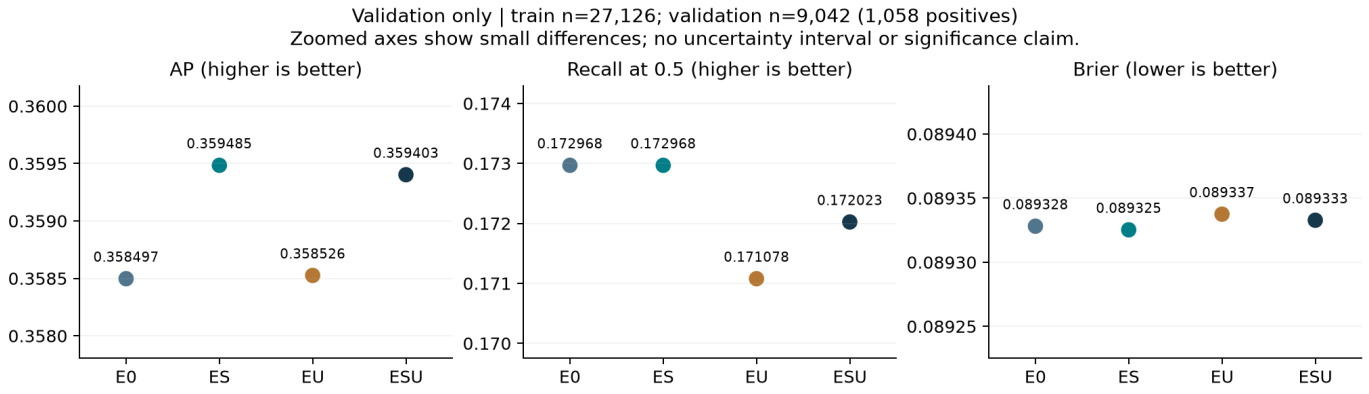
本次环境：Python 3.12.14，scikit-learn 1.8.0，numpy 2.5.4，pandas 3.0.6。A 的原环境锁保留；D 的实测锁见 requirements.D.lock.txt。

每一步的影响，全部保留

逐项对照

对照	ΔAP	ΔRecall（百分点）	ΔF1	ΔBrier
ES−E0	+0.00098723	+0.00000	+0.000000	−0.00000283
ESU−EU	+0.00087691	+0.09452	+0.001308	−0.00000474
EU−E0	+0.00002833	−0.18904	−0.002614	+0.00000939
ESU−ES	−0.00008200	−0.09452	−0.001306	+0.00000747
ESU−E0	+0.00090523	−0.09452	−0.001306	+0.00000465

Δ 均为前者减后者。AP / Recall / F1 越大越好，Brier 越小越好；不把不同指标单位混为“提升百分比”。S 有两种 U 条件下的比较，U 也有两种 S 条件下的比较，避免把总变化全归于一个步骤。



无特征参考与阈值背景

全部预测 no：Accuracy=88.2990%，Recall=0，AP=0.117010，Brier=0.117010。训练正例率恒定概率参考：p=0.116973，Brier=0.103318；0.5 阈值下同样全预测 no。四组 AP 与 Brier 优于这些参考，但 Recall 仅约 17%，仍会漏掉大部分正例。

混淆矩阵计数

实验	TP	FP	TN	FN
E0	183	79	7905	875
ES	183	79	7905	875
EU	181	79	7905	877
ESU	182	79	7905	876

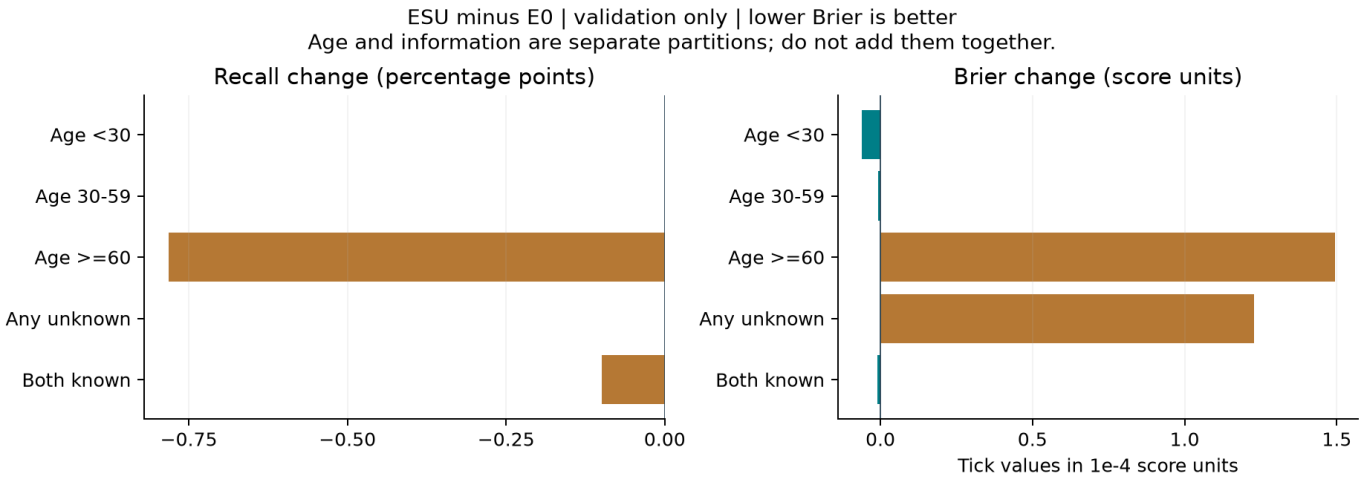
AP 是 average_precision_score，不是梯形 PR-AUC。Brier 是 mean((p−y)□)，不单独证明校准改善。分母为0时指标记为 NaN；无正例时 AP 记为无定义。保存了逐行概率，可独立复算。

整体平均之外的客群代价

手册预定分组；以下均为验证集

分组	n / 正例 / 负例	Recall E0→ESU	FPR E0→ESU	Brier E0→ESU
年龄 <30	1075 / 196 / 879	0.173469 → 0.173469	0.019340 → 0.019340	0.131222 → 0.131216
年龄 30–59	7603 / 734 / 6869	0.163488 → 0.163488	0.007279 → 0.007279	0.076871 → 0.076871
年龄 ≥60	364 / 128 / 236	0.226562 → 0.218750	0.050847 → 0.050847	0.225793 → 0.225942
任一 unknown	407 / 46 / 361	0.217391 → 0.217391	0.016620 → 0.016620	0.083210 → 0.083333
两列均已知	8635 / 1012 / 7623	0.170949 → 0.169960	0.009576 → 0.009576	0.089616 → 0.089616

年龄与信息完整性是两套分组，互相重叠；不可相加。完整性由原始 job 或 education 是否包含文字 unknown 定义，不使用填补后的值。所有四组的完整组表和差值见 CSV。



需要在结论中保留的变化

≥60 岁：E0 识别 29/128 个正例，ESU 为 28/128，少1个；Recall 下降0.78125个百分点，Brier 增加0.00014935。任一 unknown 组：两方案均识别10/46个正例，Recall 不变，但 Brier 增加0.00012293。

本次各组均未触发 n<100 或正/负例<20 的展示警告；这不等于结果精确或差异显著。没有客户级独立性、时间外验证或歧视判定依据。解释须与 B 的训练集证据核对。

向负责人 B 获取的材料

目的：把模型变化接回真实的训练集发现，避免凭分数猜测数据机制。

必须获取	验收内容	D 的用途
核心发现 + 可重建证据	train-only Notebook/代码；至少1张交叉表或分层表；分区、n、正例数、分母；≤4主图	解释 S/U 决策的观察依据；A 审计不能替代 B 独立发现
历史联系交叉表	pdays==-1 / ⩾0 × previous=0 / >0 × poutcome；例外原始 row_id；解释和未知原因	核对 S 的语义；讨论 previous/poutcome 的潜在冗余
unknown 分层证据	按年龄或联系状态的 job/education unknown 比例及认购率；总体/分层比较	解释 U 和组内代价；没有反转证据时不称辛普森悖论
提前固定分组	确认年龄 <30、30-59、⩾60；原始两列任一 unknown / 均已知	保证组别不是看过测试后挑选；若修改须先重新确认协议
解释人工复核	对全部改善/恶化/无变化提出书面意见；真实姓名与日期	形成最终结论和视频；不得用自动化代签

建议索取的文件

B_discovery.ipynb；B_history_crosstab.csv；B_unknown_strata.csv；B_findings.md；B_groups_review.md。名称可以不同，必须拿到代码和原始表，不能只有截图或口头结论。

可以直接复制给 B 的交接请求

“我是 LIANG SHUANG，负责 D。请给我仅基于固定 train 的核心发现、历史联系三字段交叉表、unknown 的分层表，以及每张图的 n/正例数/分母和可复现代码。请确认手册预定分组，并复核我四组验证结果中‘改善很小、部分客群变差’的解释。请附真实复核姓名和日期，之后再冻结并执行最终测试。”

以上是草稿，未代你联系或发送给任何成员。

C 的接入验收与剩余缺口

材料	本次接入情况	状态
正式管线	src/preprocessing.py 原字节保留；四开关、模型和白名单一致	已接入；配置指向 src.preprocessing
S/U 与防泄漏测试	14项C测试和12项D检查通过；包含哨兵、unknown、未见类别、fit边界和序列化	本机重新验证，不只采信原包日志
特征与系数	编码维数31/32/33/34；类别块顺序变化，特征名和系数表已重新生成	按规范特征名对齐后输入矩阵完全一致
环境与历史结果	统一使用D锁重跑；C原环境锁单独保留；旧D结果归档	概率最大差异<1e-12，分类变化0条
整合与人工复核	ZIP未含说明提及的analysis.ipynb；已补A+C+D整合草稿	B章节、实际人工确认、最终测试和录制仍待完成

现在只需向 C 确认

“C 的正式代码和测试已在我的环境接入并复跑通过。请告知你的姓名并确认已经理解、复核这版 S/U 管线及共同约定；如果有更新版整合 Notebook，请一并提供。当前我已补 A+C+D 草稿，B 章节和最终测试仍留空。收齐 B 后请核对最终装配、贡献与 GenAI 声明。”

收齐之后运行

1. 收 B 的发现、分层表与分组确认；2. 完成实际人工核验，填写交接记录并附证据路径；3. 运行 freeze；4. test 用 train+val 重拟合并报告四组测试；5. 更新结论、单一 Notebook 与视频。

命令：.venv/Scripts/python.exe scripts/run_d.py validate
.venv/Scripts/python.exe scripts/run_d.py freeze --receipt config/d_handoff_receipt.json
.venv/Scripts/python.exe scripts/run_d.py test

冻结记录保存源码、数据、split、环境和验证证据哈希；测试独占标记阻止重复执行。若测试中途故障，保留原始记录供复核，不自动删除标记或重试。

D 的讲解主线与最终核对

视频 07:50 – 10:35：约 2 分 45 秒

当前是验证版讲稿。最终视频应改用正式测试结果并明确 train+val 重拟合；不能把当前验证数值改称测试数值。英文完整稿与阶段提示见 notes/D_VIDEO_SCRIPT.md。

先交代公平对照

四组同一模型、同一数据划分、同一0.5阈值。只比较 S/U 两项准备规则；先验证，后冻结与测试。

整体结果

AP 约0.3585至0.3595。S 有很小排序改善；U 的效果混合，不能承诺提升。完整准备并未同时改善所有指标。

背景参考

全部预测 no 的 Accuracy 已达88.30%。模型约89.4%的 Accuracy 不应掩盖只有17%左右的 Recall。

分组代价

≥60岁组 ESU 比 E0 少识别1个正例。原始信息含unknown组的Recall不变，Brier稍差。保留变差结果，说明总体平均可能掩盖局部代价。

解释与限制

语义正确性与可解释性仍有价值；已有历史变量可能冗余，待B证据支持。无显著性、因果、未来泛化或收益承诺。

交付与诚信核对

已提供：C正式源码与测试、D评估与全部验证表、D Notebook、A+C+D整合草稿、更新讲稿。仍缺：B核心发现与分层证据、成员实际复核、最终测试、完整Notebook封版、四人视频和实际课程提交。详见 notes/D_MISSING_ITEMS.md。

GenAI：OpenAI Codex 辅助代码、运行、核算与文字组织。用户声明 LIANG SHUANG 为 D；未声称任何学生已经人工核验。需要学生实际理解、审阅和录制。

自动化：A的10项治理检查、C的14项转换检查、D的12项评估检查均通过；D、C及A+C+D草稿均已新内核运行。自动化不代替成员实际理解与确认。

依据：本地执行手册第6–10页；A仓库 commit b4c4ff1be75a6e48baacd920f405982b20399352；scikit-learn 1.8 AP / Brier / Common pitfalls 官方文档。详见 notes/D_HANDOFF.md 和 Notebook 的可点击引用。