# 四组对照评估：当前可交付成果

## 负责人 D：LIANG SHUANG

状态：验证实验已完成；最终测试等待 B/C 交接。 本报告使用 A 的固定数据与划分，并由 D 按手册第6页临时补齐管线。结果可复现，但 C 尚未确认实现，B 尚未复核解释，不能称为全组最终结论。

研究问题：特殊值语义与未知信息处理如何影响同一逻辑回归的可靠性？不调参，不改变阈值，不增加复杂模型。

| 实验 | S：联系历史表示 | U：job/education unknown |
|---|---|---|
| E0 | 原始 pdays，保留 -1 | 训练集众数填补 |
| ES | 状态标记 + 条件间隔 | 训练集众数填补 |
| EU | 原始 pdays，保留 -1 | 独立类别 |
| ESU | 状态标记 + 条件间隔 | 独立类别 |

## 实际验证结果

| 实验 | AP ↑ | Recall ↑ | F1 ↑ | Brier ↓ | Accuracy |
|---|---|---|---|---|---|
| E0 | 0.358497 | 0.172968 | 0.277273 | 0.089328 | 0.894492 |
| ES | 0.359485 | 0.172968 | 0.277273 | 0.089325 | 0.894492 |
| EU | 0.358526 | 0.171078 | 0.274659 | 0.089337 | 0.894271 |
| ESU | 0.359403 | 0.172023 | 0.275967 | 0.089333 | 0.894382 |

train：27,126 行、3,173 正例；validation：9,042 行、1,058 正例、7,984 负例。阈值 p≥0.5。四组输入样本完全相同，编码后维数依次为 31 / 32 / 33 / 34；全部收敛，无收敛警告。

## 核心结论：语义更清楚，不等于所有指标都更好。

S 的 AP 改善很小；U 的方向不稳定。ESU 相对 E0 的 AP 增加 0.000905，但 Recall 减少 0.0945 个百分点、Brier 增加约 0.00000465。没有不确定性区间，不能称为显著改善。

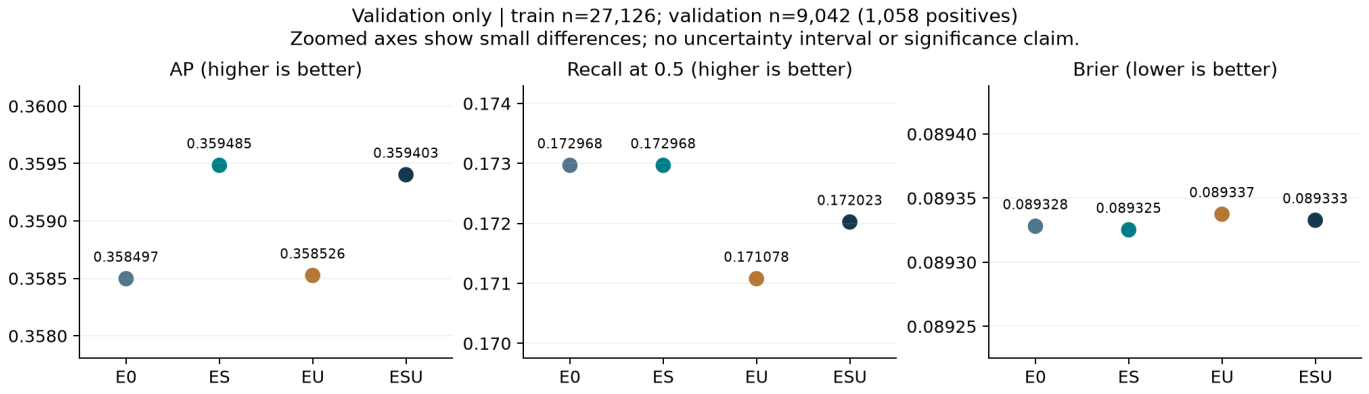
本次环境：Python 3.12.14，scikit-learn 1.8.0，numpy 2.5.4，pandas 3.0.6。A 的原环境锁保留；D 的实测锁见 requirements.D.lock.txt。

# 每一步的影响，全部保留

## 逐项对照

| 对照 | ΔAP | ΔRecall（百分点） | ΔF1 | ΔBrier |
|---|---|---|---|---|
| ES−E0 | +0.00098723 | +0.00000 | +0.000000 | −0.00000283 |
| ESU−EU | +0.00087691 | +0.09452 | +0.001308 | −0.00000474 |
| EU−E0 | +0.00002833 | −0.18904 | −0.002614 | +0.00000939 |
| ESU−ES | −0.00008200 | −0.09452 | −0.001306 | +0.00000747 |
| ESU−E0 | +0.00090523 | −0.09452 | −0.001306 | +0.00000465 |

Δ 均为前者减后者。AP / Recall / F1 越大越好，Brier 越小越好；不把不同指标单位混为“提升百分比”。S 有两种 U 条件下的比较，U 也有两种 S 条件下的比较，避免把总变化全归于一个步骤。




## 无特征参考与阈值背景

全部预测 no：Accuracy=88.2990%，Recall=0，AP=0.117010，Brier=0.117010。训练正例率恒定概率参考：p=0.116973，Brier=0.103318；0.5 阈值下同样全预测 no。四组 AP 与 Brier 优于这些参考，但 Recall 仅约 17%，仍会漏掉大部分正例。

## 混淆矩阵计数

| 实验 | TP | FP | TN | FN |
|---|---|---|---|---|
| E0 | 183 | 79 | 7905 | 875 |
| ES | 183 | 79 | 7905 | 875 |
| EU | 181 | 79 | 7905 | 877 |
| ESU | 182 | 79 | 7905 | 876 |

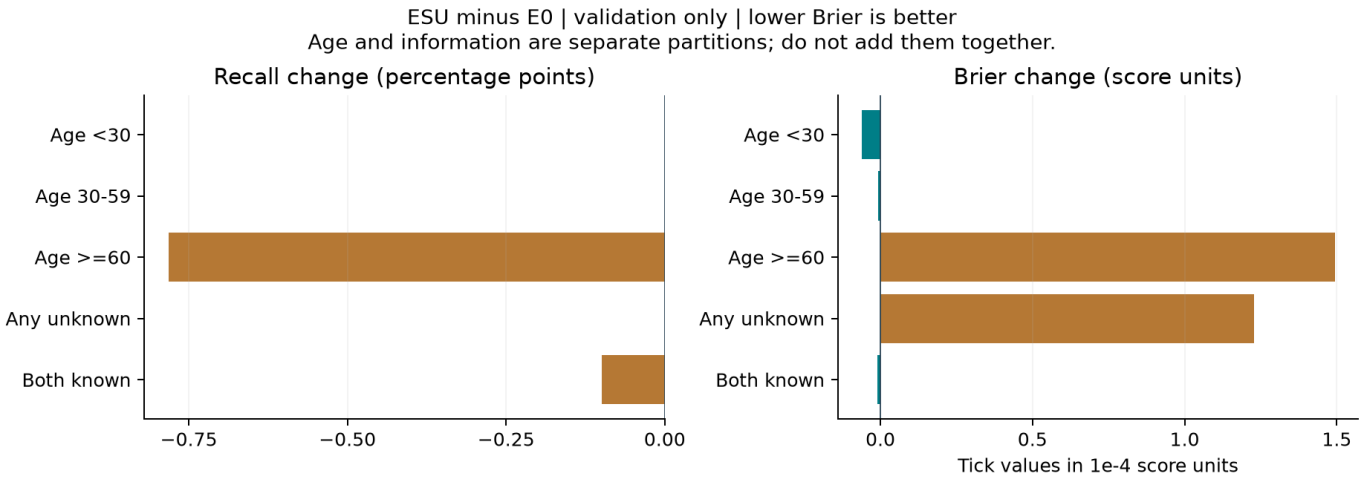
AP 是 average_precision_score，不是梯形 PR-AUC。Brier 是 mean((p−y)□)，不单独证明校准改善。分母为0时指标记为 NaN；无正例时 AP 记为无定义。保存了逐行概率，可独立复算。

# 整体平均之外的客群代价

## 手册预定分组；以下均为验证集

| 分组 | n / 正例 / 负例 | Recall E0→ESU | FPR E0→ESU | Brier E0→ESU |
|---|---|---|---|---|
| 年龄 <30 | 1075 / 196 / 879 | 0.173469 → 0.173469 | 0.019340 → 0.019340 | 0.131222 → 0.131216 |
| 年龄 30–59 | 7603 / 734 / 6869 | 0.163488 → 0.163488 | 0.007279 → 0.007279 | 0.076871 → 0.076871 |
| 年龄 ≥60 | 364 / 128 / 236 | 0.226562 → 0.218750 | 0.050847 → 0.050847 | 0.225793 → 0.225942 |
| 任一 unknown | 407 / 46 / 361 | 0.217391 → 0.217391 | 0.016620 → 0.016620 | 0.083210 → 0.083333 |
| 两列均已知 | 8635 / 1012 / 7623 | 0.170949 → 0.169960 | 0.009576 → 0.009576 | 0.089616 → 0.089616 |

年龄与信息完整性是两套分组，互相重叠；不可相加。完整性由原始 job 或 education 是否包含文字 unknown 定义，不使用填补后的值。所有四组的完整组表和差值见 CSV。




## 需要在结论中保留的变化

≥60 岁：E0 识别 29/128 个正例，ESU 为 28/128，少1个；Recall 下降0.78125个百分点，Brier 增加0.00014935。任一 unknown 组：两方案均识别10/46个正例，Recall 不变，但 Brier 增加0.00012293。

本次各组均未触发 n<100 或正/负例<20 的展示警告；这不等于结果精确或差异显著。没有客户级独立性、时间外验证或歧视判定依据。解释须与 B 的训练集证据核对。

# 向负责人 B 获取的材料

目的：把模型变化接回真实的训练集发现，避免凭分数猜测数据机制。

| 必须获取 | 验收内容 | D 的用途 |
| --- | --- | --- |
| 核心发现 + 可重建证据 | train-only Notebook/代码；至少1张交叉表或分层表；分区、n、正例数、分母；≤4主图 | 解释 S/U 决策的观察依据；A 审计不能替代 B 独立发现 |
| 历史联系交叉表 | pdays==-1 / ⩾0 × previous=0 / >0 × poutcome；例外原始 row_id；解释和未知原因 | 核对 S 的语义；讨论 previous/poutcome 的潜在冗余 |
| unknown 分层证据 | 按年龄或联系状态的 job/education unknown 比例及认购率；总体/分层比较 | 解释 U 和组内代价；没有反转证据时不称辛普森悖论 |
| 提前固定分组 | 确认年龄 <30、30-59、⩾60；原始两列任一 unknown / 均已知 | 保证组别不是看过测试后挑选；若修改须先重新确认协议 |
| 解释人工复核 | 对全部改善/恶化/无变化提出书面意见；真实姓名与日期 | 形成最终结论和视频；不得用自动化代签 |

## 建议索取的文件

B_discovery.ipynb；B_history_crosstab.csv；B_unknown_strata.csv；B_findings.md；B_groups_review.md。名称可以不同，必须拿到代码和原始表，不能只有截图或口头结论。

## 可以直接复制给 B 的交接请求

“我是 LIANG SHUANG，负责 D。请给我仅基于固定 train 的核心发现、历史联系三字段交叉表、unknown 的分层表，以及每张图的 n/正例数/分母和可复现代码。请确认手册预定分组，并复核我四组验证结果中‘改善很小、部分客群变差’的解释。请附真实复核姓名和日期，之后再冻结并执行最终测试。”

以上是草稿，未代你联系或发送给任何成员。

# 向负责人 C 获取的材料

| 必须获取 | 验收内容 | D 的用途 |
| --- | --- | --- |
| 正式 build_pipeline | build_pipeline(use_s,use_u)；fit / predict_proba / 特征名接口；11列原始输入；同一固定 LR | 替换临时模块或正式采纳并审阅 D 的参考实现 |
| S 转换测试 | -1、0、正数区分；原 pdays 移除；<-1 / 真缺失停止核查；状态标记0/1 | 排除把未联系当作当天联系；共同缩放约定一致 |
| U 与拟合边界测试 | 只改 job/education unknown；poutcome 不改；众数/中位数/缩放/OHE 只在当前 fit 数据学得 | 避免泄漏；四组行数、顺序、固定 split 不变 |
| 版本与证据 | 源文件/提交号、四组配置、测试代码和日志、依赖锁、编码后特征名与维数 | 在 D 环境复现；不能仅交全表 fit 后的矩阵 |
| 最终 Notebook 装配 | 合并 A/B/C/D 关键函数、结果、引用和 GenAI 声明；保留待办和真实贡献 | C 总装；A 新内核 Run All；D 校对所有图文数字 |

## 可以直接复制给 C 的交接请求

“我是 LIANG SHUANG，负责 D。请交正式 build_pipeline(use_s,use_u) 模块、四组配置和 S/U 边界及无泄漏测试。D 已按手册做参考实现并完成验证，你可以审阅采纳或替换；请明确状态标记的缩放约定、全部学习参数的 fit 分区和真实复核记录。我会使用接受后的管线重新验证，再冻结最终测试。请将 D_evaluation.ipynb 的核心单元并入全组 Notebook。”

## 收齐之后运行

1. 接受/替换管线并重跑 validate、QA；2. 填真实 d_handoff_receipt.json，附 B/C 证据路径；3. 运行 freeze；4. test 一次性重拟合 train+val 并报告四组测试；5. 更新结论并由 B 复核。

命令：.venv/Scripts/python.exe scripts/run_d.py validate
.venv/Scripts/python.exe scripts/run_d.py freeze --receipt config/d_handoff_receipt.json
.venv/Scripts/python.exe scripts/run_d.py test

冻结记录保存源码、数据、split、环境和验证证据哈希；测试独占标记阻止重复执行。若测试中途故障，保留原始记录供复核，不自动删除标记或重试。

# D 的讲解主线与最终核对

## 视频 07:50 – 10:35：约 2 分 45 秒

当前是验证版讲稿。最终视频应改用正式测试结果并明确 train+val 重拟合；不能把当前验证数值改称测试数值。英文完整稿与阶段提示见 notes/D_VIDEO_SCRIPT.md。

## 先交代公平对照

四组同一模型、同一数据划分、同一0.5阈值。只比较 S/U 两项准备规则；先验证，后冻结与测试。

## 整体结果

AP 约0.3585至0.3595。S 有很小排序改善；U 的效果混合，不能承诺提升。完整准备并未同时改善所有指标。

## 背景参考

全部预测 no 的 Accuracy 已达88.30%。模型约89.4%的 Accuracy 不应掩盖只有17%左右的 Recall。

## 分组代价

≥60岁组 ESU 比 E0 少识别1个正例。原始信息含unknown组的Recall不变，Brier稍差。保留变差结果，说明总体平均可能掩盖局部代价。

## 解释与限制

语义正确性与可解释性仍有价值；已有历史变量可能冗余，待B证据支持。无显著性、因果、未来泛化或收益承诺。

## 交付与诚信核对

已提供：D Notebook、源码、四组验证 CSV、逐行概率、5项增量、分组表、系数、检查与讲稿。未完成的依赖：B/C 材料与真实签字、最终测试、C 全组整合、A 新内核复核、四人视频和课程实际提交。

GenAI：OpenAI Codex 辅助代码、运行、核算与文字组织。用户声明 LIANG SHUANG 为 D；未声称任何学生已经人工核验。需要学生实际理解、审阅和录制。

自动化：A 的10项数据治理检查、D 的边界/指标/拟合边界/封版检查均通过；D Notebook 新内核9个代码单元运行成功，无错误。检查报告见 outputs/D/。

依据：本地执行手册第6–10页；A仓库 commit b4c4ff1be75a6e48baacd920f405982b20399352；scikit-learn 1.8 AP / Brier / Common pitfalls 官方文档。详见 notes/D_HANDOFF.md 和 Notebook 的可点击引用。